

Un Cadre Neuro-Symbolique pour les Modèles du Monde Multi-Agents

Julien Soulé^a
julien.soule@uni.lu

Jean-Paul Jamont^b
jean-paul.jamont@lcis.grenoble-inp.fr

^aSEDAN Research Group, SnT, University of Luxembourg, Luxembourg, Luxembourg

^bUniv. Grenoble Alpes, Grenoble INP, LCIS, 26000, Valence, France

Résumé

Les modèles du monde (World Models, WMs) sont des modèles prédictifs de la dynamique d'un environnement, essentiels en apprentissage par renforcement basé modèle (Model-Based Reinforcement Learning, MBRL). En contexte multi-agent partiellement observable, ils souffrent de l'ambiguïté des observations locales et de l'accumulation d'erreurs. Les WMs multi-agents (MAWMs) neuronaux produisent alors fréquemment des prédictions incohérentes sémantiquement. Nous proposons Neuro-Symbolic Multi-Agent World Models (NS-MAWM), qui intègre un raisonnement symbolique dans les transitions d'observation via des contraintes différentiables jouant le rôle de biais inductifs contre la dérive sémantique. Nous évaluons NS-MAWM dans quatre environnements selon trois stratégies d'intégration et observons une amélioration de la fidélité prédictive et de la cohérence symbolique.

Mots-clés : Apprentissage par Renforcement Multi-Agent Basé Modèle, Modèles du Monde Multi-Agents, Neuro-Symbolique

Abstract

World models (WMs) are predictive models of environmental dynamics, essential in model-based reinforcement learning (MBRL). In partially observable multi-agent contexts, they suffer from ambiguity in local observations and error accumulation. Neural multi-agent WMs (MAWMs) thus frequently produce semantically inconsistent predictions. We propose Neuro-Symbolic Multi-Agent World Models (NS-MAWM), which integrates symbolic reasoning into observation transitions via differentiable constraints acting as inductive biases against semantic drift. We evaluate NS-MAWM in four environments using three integration strategies and observe improvements in predictive accuracy and symbolic consistency.

Keywords: Model-Based MARL, Multi-Agent World Models, Neuro-Symbolic Learning

1 Introduction

Les modèles du monde (*World Models*, WMs) sont au cœur de l'apprentissage par renforcement basé modèle (*Model-Based Reinforcement Learning*, MBRL) [1, 2, 3, 4]. Ils soutiennent la *planification par imagination* [2], mais leur extension à un environnement multi-agent partiellement observable reste difficile [5, 6, 7].

Dans ce contexte, les observations décrivent des entités interactives soumises à des contraintes spatiales, logiques et physiques. Les WMs à base de réseaux de neurones peinent souvent à préserver cette structure [8] : ils peuvent produire des prédictions numériquement plausibles mais sémantiquement invalides (par exemple, deux agents sur la même cellule). Ces erreurs se cumulent au fil des étapes imaginées, dégradant la précision et la planification en aval [9].

Cette problématique s'inscrit dans la continuité de nos travaux en apprentissage par renforcement multi-agent neuro-symbolique [10]. Nos précédentes contributions ont intégré des abstractions organisationnelles dans l'apprentissage pour améliorer le contrôle et l'explicabilité, mais elles ont aussi révélé une dépendance critique à la qualité du modèle environnemental. Nous nous concentrons donc ici sur l'apprentissage d'un modèle du monde multi-agents fiable, préalable au guidage organisationnel.

Plusieurs travaux ont intégré des connaissances a priori dans les WMs [8, 11, 7]. L'intégration d'un raisonnement symbolique dans les WMs multi-agents reste incomplète sur trois *gaps* :

G1 Structures de WMs orientées multi-agents.

Les WMs négligent souvent des a priori essentiels : représentation explicite de l'observabilité partielle, non-stationnarité induite par les interactions, et modularité des entités [12, 13, 6]. Ils supposent fréquemment des dynamiques quasi stationnaires et traitent les agents uniformément, limitant la généralisation.

G2 Intégration neuro-symbolique dans les WMs. Bien que les a priori symboliques (contraintes d'action, lois physiques, règles d'interaction) améliorent les politiques entraînées, peu de modèles les intègrent dans l'apprentissage des WMs [14, 15, 11, 16]. La plupart s'appuient uniquement sur des dynamiques latentes « boîte noire », manquant des opportunités d'exploiter la connaissance symbolique comme biais inductif.

G3 Métriques pour la cohérence des MAWMs neuro-symboliques. Les métriques standard se concentrent sur la précision prédictive ou la récompense en aval, en ignorant la cohérence symbolique. Pourtant, les jeux d'évaluation rapportent rarement des métriques de validité logique [9, 11], réduisant cette dimension dans l'évaluation.

En nous appuyant sur des cadres d'intégration neuro-symbolique [17, 16, 14, 15], nous proposons *Neuro-Symbolic Multi-Agent World Models* (NS-MAWM). Ce cadre s'articule autour de :

- Un **espace latent structuré** décomposant les observations en entités typées avec des attributs interprétables (position, type), permettant l'application des règles symboliques.
- Un **formalisme de règles symboliques** exprimant les contraintes de l'environnement de manière différentiable sur les observations et actions, spécifiant clairement invariants et équivariances.
- Trois stratégies d'intégration neuro-symbolique : i) **Régularisation** encodant les règles comme contraintes souples différentiables ; ii) **Projection** corrigeant les violations en projetant sur des configurations valides ; iii) **Résiduelle** factorisée en processus symbolique et résidus appris.
- Un **taux de violation des règles** quantifiant les violations de contraintes pour évaluer la cohérence logique.

Nous évaluons NS-MAWM sur quatre environnements : *Gridcraft*, *Overcooked* [18], *Predator Prey* [19] et *SMACv2* [20]. Les variantes neuro-symboliques améliorent systématiquement la fidélité prédictive et la cohérence symbolique, la dynamique résiduelle offrant le meilleur compromis global entre cohérence long-terme et coût.

La Section 2 situe nos contributions dans l'état de l'art. La Section 3 introduit le formalisme et les bases requises pour présenter NS-MAWM dans la Section 4. La Section 5 détaille le cadre expérimental dont les résultats sont présentés et discutés dans la Section 6. Enfin, la Section 7 conclut et ouvre sur des perspectives futures.

2 Travaux connexes

Nous analysons l'état de l'art à travers les quatre dimensions ci-dessous.

Architectures de WMs. Sur l'axe architectural, les approches fondatrices telles que *Dreamer* [3, 4] et *PlaNet* [2] proposent des modèles de dynamique latente boîte noire puissants, mais avec un espace latent souvent monolithique sans biais explicite vers les entités ou les agents. Des efforts complémentaires adoptent une représentation plus structurée. Par exemple, *WM as Graph* [12] et *Bi-Level Latent-Variable World Model for Sample-Efficient Multi-Agent Reinforcement Learning* (MABL) [6] proposent une modularité latente alignée avec les entités et la topologie de l'environnement. *Multi-Agent Model-Based Policy Optimization* (MAMBPO) [13] intègre une structure multi-agent, permettant des simulations conditionnées par les vues individuelles des agents. Ces travaux améliorent la structure interne des modèles, mais n'adressent pas systématiquement la cohérence symbolique.

Apprentissage en environnements multi-agents. Sur l'axe de la dynamique multi-agent, certains modèles traitent les autres agents comme une partie de l'environnement, ce qui tend à absorber leurs changements de politique dans une dynamique globale peu explicitée. Cette modélisation peut être suffisante lorsque les interactions restent simples, mais elle rend plus difficile l'analyse explicite de la non-stationnarité. *Mingling Foresight* [21] et *Multi-Timescale Multi-Agent Reinforcement Learning* [22] améliorent la gestion des interactions simultanées via un raisonnement hiérarchique ou une adaptation d'échelle temporelle. La modélisation explicite des adversaires est proposée dans [23], avec des WMs conditionnés sur des politiques adverses latentes. Ces approches ciblent la non-stationnarité, mais restent majoritairement neuronales.

Connaissances symboliques dans les WMs. Sur l'axe neuro-symbolique, plusieurs travaux injectent des connaissances de domaine comme contraintes, telles que la perte sémantique [14] et des règles logiques différentiables [15]. *Deep-ProbLog* [17] fusionne la logique probabiliste avec des modèles profonds. Des WMs neuro-symboliques récents [11, 7] proposent une structure symbolique explicite sur les dynamiques latentes pour soutenir l'adaptation et l'interprétabilité. L'état de l'art progresse nettement, mais l'intégration de règles reste encore peu systématique dans les WMs multi-agents.

Dimensions d'évaluation. Sur l'axe évaluation, la plupart des WMs sont comparés via la perte de reconstruction ou la performance de contrôle, mais peu d'études évaluent explicitement la cohérence aux règles symboliques ou la généralisation sous changements structurels. Un besoin pour des métriques plus larges, incluant la cohérence sémantique, les taux de violation de règles et la frugalité en données/temps est souvent exprimé [5]. Cet axe motive l'introduction de métriques dédiées.

Ces quatre axes structurent l'état de l'art, tandis que notre proposition cible directement trois *gaps* techniques : **(G1)** l'absence de biais architecturaux explicitement multi-agents, **(G2)** la faible intégration de mécanismes neuro-symboliques dans les WMs, et **(G3)** le manque de vérification explicite de la cohérence symbolique. Ces *gaps* motivent NS-MAWM pour soutenir un apprentissage structuré, interprétable et efficace dans des environnements multi-agents partiellement observables à dynamique évolutive.

3 Contexte et bases théoriques

Cette section introduit les éléments de formalisme utiles pour la suite, en allant du cadre MARL général vers les WMs et leur extension multi-agent.

3.1 Cadre de l'apprentissage par renforcement multi-agent

Pour étudier l'apprentissage par renforcement multi-agent (*Multi-Agent Reinforcement Learning*, MARL) coopératif sous observabilité partielle, nous adoptons le formalisme processus de décision de Markov partiellement observable décentralisé (*Decentralized Partially Observable Markov Decision Process*, Dec-POMDP) [24], qui fournit un cadre de principe pour la prise de décision décentralisée où les agents agissent sur des observations locales tout en optimisant conjointement un objectif partagé. Les Dec-POMDPs se spécialisent pour des contextes pleinement coopératifs avec récompense commune et politique optimisée conjointement.

Formellement, un Dec-POMDP est un 7-uplet $d = \langle S, \{A_i\}_{i=1}^n, T, R, \{\Omega_i\}_{i=1}^n, O, \gamma \rangle$, où S est l'espace d'états ; A_i et Ω_i sont les espaces d'actions et d'observations de l'agent i ; $T(s, a, s') = \mathbb{P}(s' \mid s, a)$ est la fonction de transition pour les actions conjointes $a = (a_1, \dots, a_n)$; $R : S \times A \times S \rightarrow \mathbb{R}$ est la récompense partagée ; $O(s', a, \omega) = \mathbb{P}(\omega \mid s', a)$ est la fonction d'observation ; et $\gamma \in [0, 1)$ est le facteur d'actualisation.

Chaque agent $i \in \mathcal{A} = \{1, \dots, n\}$ suit une politique (éventuellement stochastique) $\pi_i : \Omega_i \rightarrow \Delta(A_i)$, où $\Delta(A_i)$ désigne l'ensemble des distributions de probabilité sur A_i , et la **politique conjointe** est $\pi^j = (\pi_1, \dots, \pi_n)$. Soit H_i l'ensemble des historiques possibles de l'agent $h_i = \langle (\omega_k^i, a_k^i) \rangle_{k=0}^T$, et $H_{\text{joint}} = (H_1, H_2 \dots H_n)$ l'ensemble des historiques conjoints. π^j doit maximiser la récompense cumulée attendue selon la fonction d'état-valeur (décrite en Équation 1), soit avec un horizon fini de T étapes (ou si $\gamma < 1$), soit avec un horizon potentiellement infini lorsque $\gamma = 1$.

$$V(s_0)^{\pi^j} = \mathbb{E}_{\pi^j} \left[\sum_{t=0}^T \gamma^t R(s_t, a_t^j, s_{t+1}) \right]. \quad (1)$$

3.2 Apprentissage par renforcement multi-agent basé modèle

L'apprentissage par renforcement multi-agent basé modèle (*Model-Based Multi-Agent Reinforcement Learning*, MB-MARL) étend le MBRL à la prise de décision multi-agent. Il apprend un modèle approché de l'environnement, puis l'exploite pour la planification ou l'optimisation de politiques, afin d'améliorer l'efficacité d'apprentissage et la coordination [25, 26].

Modèles d'environnement. Dans des contextes coopératifs avec n agents, la dynamique est gouvernée par $T(s' \mid s, a_1, \dots, a_n)$ avec une récompense partagée $R(s, a_1, \dots, a_n)$. Le MB-MARL apprend des approximations $\hat{T}_\phi$ et $\hat{R}_\phi$ de la dynamique et de la récompense à partir de données d'interaction. Comparé au MBRL mono-agent, apprendre de tels modèles est plus difficile à cause des espaces d'actions conjoints, de l'observabilité partielle, et de la non-stationnarité induite par l'apprentissage [26].

Structure du modèle. Les méthodes MB-MARL diffèrent par la structure du modèle : des approches centralisées, proches du paradigme **CTDE** (*Centralized Training, Decentralized Execution*), aux approches décentralisées ou factorisées, avec un compromis entre précision globale et scalabilité [26].

Sous des hypothèses standard de qualité du modèle appris et de stabilité de la planification, la réutilisation des données via simulations réduit les interactions avec l'environnement et améliore la frugalité en données [26, 25].

3.3 Bases des WMs

Les WMs sont une classe de méthodes de MBRL qui apprennent la dynamique de l'environnement [1, 3]. Ils sont particulièrement adaptés aux contextes partiellement observables tels que les Dec-POMDPs, permettant la planification, une meilleure frugalité en données et un raisonnement par imagination. Nous retenons ici une formulation déterministe simplifiée, alors que les WMs modernes reposent généralement sur des variables latentes stochastiques entraînées par inférence variationnelle [2, 3].

Formellement, à chaque pas de temps t , soit $\omega_t \in \Omega$ l'observation, $a_t \in A$ l'action exécutée, et $\tilde{h}_{t-1} \in \mathcal{H}$ l'état caché récurrent résumant l'historique d'interaction jusqu'au temps $t-1$. Ici, $\mathcal{H}$ désigne l'espace des états cachés récurrents. Un encodeur $Enc : \Omega \rightarrow Z$ projette les observations de grande dimension dans une représentation latente compacte $z_t = Enc(\omega_t)$. L'évolution temporelle de l'état latent est modélisée par :

$$\tilde{h}_t = f_\theta(\text{concat}(\tilde{h}_{t-1}, z_t, a_t)), \hat{z}_{t+1} = g_\theta(\tilde{h}_t).$$

où $f_\theta(\cdot)$ est typiquement implémenté comme un réseau de neurones récurrent, par exemple un *Long Short-Term Memory* (LSTM) [27], et $g_\theta(\cdot)$ est une fonction paramétrique telle qu'un *Multi-Layer Perceptron* (MLP). L'état latent prédit est décodé par $Dec : Z \rightarrow \Omega$ pour produire l'observation prédite $\hat{\omega}_{t+1} = Dec(\hat{z}_{t+1})$.

3.4 Une extension aux WMs multi-agents

Une extension courante des WMs aux contextes multi-agents consiste à apprendre un modèle centralisé de dynamiques latentes sur les observations conjointes et les actions conjointes, similaire aux paradigmes CTDE [26].

Étant donné un jeu de trajectoires conjointes $\mathcal{D}_{H^j} = \{h^j\}$, avec $h^j = \langle (\omega_t^j, a_t^j) \rangle_{t=0}^T$, l'objectif est d'apprendre un modèle prédictif de la dynamique des observations conjointes, comme cela est courant en MB-MARL [26, 21].

Nous avons précédemment introduit un modèle de prédiction d'observations conjointes (*Joint-Observation Prediction Model*, JOPM) que nous considérons ici comme une brique de base des MAWMs étudiés. Dans toute cette section, l'exposant j désigne une quantité *conjointe*, c'est-à-dire définie à l'échelle de l'ensemble des agents. Le modèle s'écrit $\mathcal{T}_\theta^j : \mathcal{H} \times \Omega^j \times A^j \rightarrow \Omega^j$, où $\mathcal{H}$ désigne l'espace des états cachés récurrents,

c'est-à-dire une représentation compacte de l'historique conjoint [1, 3]. Il est paramétré par θ , qui regroupe les paramètres de la dynamique latente et du prédicteur d'observations, et peut être décrit de façon équivalente en Équation 2 :

$$\begin{aligned} z_t &= Enc^j(\text{flatten}(\omega_t^j)), \\ \tilde{h}_t &= f_\theta(\text{concat}(\tilde{h}_{t-1}, z_t, \text{flatten}(a_t^j))), \\ \hat{z}_{t+1}^j &= g_\theta(\tilde{h}_t), \hat{\omega}_{t+1}^j = \text{unflatten}(Dec^j(\hat{z}_{t+1}^j)). \end{aligned} \quad (2)$$

Au temps t , étant donné $\tilde{h}_{t-1} \in \mathcal{H}$, l'observation conjointe ω_t^j et l'action conjointe a_t^j , le modèle produit un état caché mis à jour $\tilde{h}_t$ puis une observation conjointe prédite $\hat{\omega}_{t+1}^j$. Dans la suite, nous distinguerons systématiquement l'*historique conjoint explicite* h_{t-1}^j , utilisé par les règles symboliques, de l'*état caché récurrent* $\tilde{h}_{t-1}$, utilisé par le prédicteur neuronal. Pour réduire la dimensionnalité, un encodeur partagé $Enc^j : \Omega^j \rightarrow Z$ projette les observations conjointes aplaties dans un espace latent, $z_t = Enc^j(\text{flatten}(\omega_t^j))$ [1, 21]. Les dynamiques latentes sont ensuite modélisées par $\tilde{h}_t = f_\theta(\text{concat}(\tilde{h}_{t-1}, z_t, a_t^j))$ et $\hat{z}_{t+1} = g_\theta(\tilde{h}_t)$, puis décodées via $Dec^j : Z \rightarrow \Omega^j$ pour produire $\hat{\omega}_{t+1}^j$ à partir de $Dec^j(\hat{z}_{t+1})$. La paire formée par l'encodeur et le décodeur est typiquement implémentée avec des architectures MLP, éventuellement avec attention, pour agréger l'information multi-agent et capturer les dépendances inter-agents [21, 26]. Cette formulation centralisée permet une modélisation précise des dynamiques conjointes sous entraînement centralisé, mais souffre de limitations de scalabilité et d'exécution décentralisée [26, 25].

4 WMs multi-agents neuro-symboliques

NS-MAWM augmente les WMs avec un raisonnement neuro-symbolique structuré. Un aperçu schématique est donné en Figure 1.

4.1 Espace latent d'observation structuré et formalisme neuro-symbolique unifié

Nous décomposons les observations individuelles et définissons un opérateur de transition symbolique capable de prédire partiellement les observations futures. Les composantes explicitement couvertes par des règles sont ainsi distinguées de celles qui doivent rester apprises à partir des données.

Représentation des observations. Nous supposons que l'observation d'un agent i au temps t peut être exprimée comme un vecteur $\omega_{i,t} = (f_{1,t}, f_{2,t}, \dots, f_{n_f,t})$, où chaque $f_{k,t}$ (avec $1 \leq k \leq n_f$) est une caractéristique numérique ou catégorielle véhiculant un attribut perceptif spécifique (par exemple une position relative, un type d'objet observé, etc.), et n_f est le nombre de caractéristiques par observation.

Déterminabilité des caractéristiques. Nous postulons que certaines caractéristiques sont *déterminables* uniquement à partir de l'observation conjointe ω_t^j , de l'action conjointe a_t^j , et de l'historique conjoint h_{t-1}^j . Ces caractéristiques sont sensibles aux invariants et régularités symboliques, telles que la cohérence spatiale ou le mouvement relatif des agents. Par exemple, dans une grille, si l'agent j se déplace vers le sud, et qu'il n'y a pas d'obstacles, alors l'agent i observant l'agent j à sa gauche devrait ensuite l'observer en bas à gauche. Nous écrivons donc $\omega_{i,t} = \text{concat}(\omega_{i,t}^d, \omega_{i,t}^u) = (f_{1,t}^d, \dots, f_{m,t}^d, f_{m+1,t}^u, \dots, f_{n_f,t}^u)$, où $f_{k,t}^d \in \mathcal{F}^d$ sont des caractéristiques déterminables via le raisonnement symbolique, tandis que $f_{k,t}^u \in \mathcal{F}^u$ sont indéterminables. En conséquence, une observation se compose de deux sous-parties : i) $\omega_{i,t}^d$: le sous-vecteur des caractéristiques déterminables (la partie inférieure du vecteur d'observation dans la Figure 1); ii) $\omega_{i,t}^u$: le sous-vecteur des caractéristiques indéterminables (la partie supérieure du vecteur d'observation dans la Figure 1).

Règles symboliques atomiques. Nous définissons une règle de transition symbolique atomique $s \in \mathcal{S}$ par $s(h_{t-1}^j, \omega_t^j, a_t^j, f_{l,t}^d) = f_{l,t+1}^d$, ce qui exprime comment une caractéristique déterminable donnée $f_{l,t}^d \in \mathcal{F}^d$ (avec $1 \leq l \leq m$) évolue sous connaissance symbolique (par exemple en imposant des contraintes de mouvement spatial fondées sur l'information passée et présente pour prédire la valeur de caractéristiques connexes).

Transition symbolique partielle. En agrégeant toutes les règles symboliques, nous définissons un opérateur de transition symbolique partiel $\mathcal{T}_s^j(h_{t-1}^j, \omega_t^j, a_t^j) = \omega_{t+1}^{d,j}$, où $\omega_{t+1}^{d,j}$ est l'observation conjointe prédite au temps $t+1$, ne contenant que les caractéristiques déterminables pour tous les agents.

Vue matricielle de la transition symbolique partielle. Soit $\mathcal{M}_{\omega_t^j}$ la matrice d'observation dont les colonnes sont des vecteurs de carac-

téristiques par agent. La transition symbolique s'écrit :

$$\mathcal{T}_s^j(\mathcal{M}_{h_{t-1}^j}, \mathcal{M}_{\omega_t^j}, \mathcal{M}_{a_t^j}) = \mathcal{M}_{\omega_{t+1}^{d,j}}. \quad (3)$$

Le masque de déterminabilité $\mathcal{M}_d = \text{sgn}(|\mathcal{M}_{\omega_{t+1}^{d,j}}|)$ indique les positions couvertes par les règles symboliques, permettant une prédiction hybride sélective où le modèle neuronal traite les composantes non couvertes.

4.2 Stratégies d'intégration neuro-symbolique

Nous retenons trois stratégies d'intégration du raisonnement symbolique aux WMs appris. Elles couvrent trois modes complémentaires de la littérature neuro-symbolique [14, 15, 16] : supervision symbolique pendant l'apprentissage, correction symbolique après prédiction et factorisation hybride explicite des composantes symboliques et neuronales. Les variantes diffèrent donc par la manière dont elles exploitent l'information couverte par les règles. Soit $\hat{\omega}_{t+1}^j = \mathcal{T}_\theta^j(\tilde{h}_{t-1}, \omega_t^j, a_t^j)$ la prédiction neuronale de l'observation conjointe complète et $\omega_{t+1}^{d,j} = \mathcal{T}_s^j(h_{t-1}^j, \omega_t^j, a_t^j)$ la prédiction symbolique partielle.

Stratégie de régularisation de cohérence symbolique. Cette stratégie ajoute une supervision symbolique comme contrainte souple. Le modèle neuronal (JOPM) est encouragé à produire des sorties $\hat{\omega}_{t+1}^j$ alignées sur les prédictions symboliques là où cette connaissance est disponible, sans imposer de garantie dure à l'inférence. Elle s'inscrit dans la lignée des pertes auxiliaires utilisées dans les modèles hybrides [14, 16]. Soit $\hat{\omega}_{t+1}^{d,j} = \mathcal{M}_d \odot \hat{\omega}_{t+1}^j$ et $\omega_{t+1}^{d,j}$ sa contrepartie symbolique (respectivement les vecteurs de droite supérieurs et inférieurs de la sous-figure **Régularisation** de la Figure 1, que l'on cherche idéalement à rendre égaux). La perte de cohérence symbolique est définie par $\mathcal{L}_{\text{sym}} = \|\hat{\omega}_{t+1}^{d,j} - \omega_{t+1}^{d,j}\|^2$ et s'ajoute à la perte prédictive principale selon $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{pred}} + \lambda \mathcal{L}_{\text{sym}}$, où λ est un coefficient de régularisation. Le modèle apprend ainsi des dynamiques plus cohérentes avec les règles, sans sortir du cadre différentiable.

Stratégie de projection symbolique. Cette stratégie remplace une partie de la prédiction neuronale par la connaissance symbolique. Les composantes couvertes sont directement projetées depuis le modèle symbolique :

$$\hat{\omega}_{t+1}^{proj,j} = \mathcal{M}_d \odot \omega_{t+1}^{d,j} + (1 - \mathcal{M}_d) \odot \hat{\omega}_{t+1}^j. \quad (4)$$




FIGURE 1 – Aperçu de NS-MAWM : $\mathcal{T}_s^j$ prédit les caractéristiques déterminables et $\mathcal{T}_\theta^j$ la transition complète. Les trois variantes illustrées sont la régularisation, la projection et la dynamique résiduelle.

La sortie projetée $\hat{\omega}_{t+1}^{proj,j}$ respecte ainsi les contraintes symboliques sur les caractéristiques déterminables. Les valeurs prédites symboliquement (vecteur de droite supérieur) remplacent les valeurs correspondantes dans le vecteur d’observation complet prédit neuronalement (vecteur de droite inférieur) pour former le vecteur d’observation complet $\omega_{t+1}^{proj,j}$ dans la sous-figure **Projection** de la Figure 1. Elle peut être utilisée comme : i) entrée pour la planification en aval ; ii) cible pour réentraîner le WM (amorçage de la conformité symbolique) ; iii) couche de correction explicite pour améliorer la fidélité des simulations. Les contraintes symboliques sont ainsi imposées directement sur les caractéristiques déterminables, tandis que la prédiction neuronale reste inchangée sur les composantes non couvertes.

Stratégie de dynamique symbolique résiduelle. Ici, nous séparons explicitement la prédiction symbolique de la prédiction neuronale. Le prédicteur neuronal est entraîné *uniquement* sur les caractéristiques qui ne sont pas déterminables à partir des connaissances symboliques. Ce partitionnement architectural s’inspire des cadres

d’apprentissage résiduel en raisonnement neuro-symbolique [16, 11]. Le modèle symbolique calcule $\omega_{t+1}^{d,j} = \mathcal{T}_s^j(h_{t-1}^j, \omega_t^j, a_t^j)$, tandis que le modèle neuronal $\mathcal{T}_\theta^{u,j}$ est entraîné à prédire $\hat{\omega}_{t+1}^{u,j} = \mathcal{T}_\theta^{u,j}(\tilde{h}_{t-1}, \omega_t^{u,j}, a_t^j)$. La prédiction finale est alors assemblée selon $\hat{\omega}_{t+1}^j = \hat{\omega}_{t+1}^{res,j} = [\omega_{t+1}^{d,j}, \hat{\omega}_{t+1}^{u,j}]$.

Cette stratégie réduit la complexité du modèle : les règles gèrent les motifs déterministes, tandis que le réseau apprend les composantes indéterminables. Le prédicteur neuronal $\mathcal{T}_\theta^{u,j}$ est restreint à $\omega_t^{u,j}$, et la prédiction finale est assemblée en combinant les sorties symboliques et neuronales (voir sous-figure **Résiduel** de la Figure 1). Pour assurer une comparaison équitable, nous conservons la même architecture (dimension latente, noyau récurrent, profondeur MLP) entre variantes, seule la couche de sortie étant adaptée à la dimension de $\omega^{u,j}$.

4.3 Correction symbolique post-prédiction des caractéristiques neuronales

Nous ajoutons enfin un mécanisme de post-correction symbolique qui impose la cohérence symbolique sur la prédiction neuronale $\hat{\omega}_{t+1}^j$ au moment de l’inférence, sans réentraînement, via : $\hat{\omega}_{t+1}^j = \mathcal{C}^s(\hat{\omega}_{t+1}^j)$, où $\mathcal{C}^s$ applique des contraintes symboliques spécifiques au domaine (comme l’exclusivité mutuelle, des transitions d’états valides ou la discrétisation de caractéristiques catégorielles). Cette correction améliore la cohérence sémantique des observations prédites lorsque des violations ponctuelles subsistent. Nous ne l’incluons pas dans la comparaison quantitative principale ; elle reste surtout pertinente pour le modèle neuronal de base et pour la variante par régularisation, lorsque des violations résiduelles persistent à l’inférence.

4.4 Taux de violation des règles

Nous quantifions la cohérence symbolique via le *Rule Violation Rate* (RVR), qui mesure la fréquence des violations de règles. Étant donnée la prédiction symbolique $\omega_{t+1}^{d,j} = \mathcal{T}_s^j(h_{t-1}^j, \omega_t^j, a_t^j)$ et la prédiction JOPM $\hat{\omega}_{t+1}^j = \mathcal{T}_\theta^j(\tilde{h}_{t-1}, \omega_t^j, a_t^j)$, l’indicateur de violation est :

$$v_{i,k,t} = \begin{cases} 1 & \text{si } |\hat{\omega}_{i,k,t+1}^{d,j} - \omega_{i,k,t+1}^{d,j}| > \epsilon, \\ 0 & \text{sinon,} \end{cases}$$

où (i, k) indexe les agents et caractéristiques déterminables, et ϵ un seuil de tolérance. Le RVR

sur T transitions est :

$$\text{RVR} = \frac{1}{nT|\mathcal{F}^d|} \sum_{t=1}^T \sum_{i=1}^n \sum_{k \in \mathcal{F}^d} v_{i,k,t}. \quad (5)$$

Un RVR faible indique une cohérence symbolique forte. Il est informatif pour les WMs neuronaux et la régularisation ; pour projection et résiduel, les caractéristiques déterminables sont imposées par construction, donnant un RVR nul.

5 Évaluation

Notre protocole d'évaluation est organisé autour de quatre axes en lien avec les *gaps* G1–G3 introduits en Section 1 : (i) **fidélité prédictive à long horizon** (biais de modèle et erreurs cumulées), (ii) **cohérence symbolique** (respect des règles), (iii) **contrôle en aval** (planification / performance de politique), et (iv) **généralisation et robustesse** (nouvelles configurations et couverture partielle des règles). Nous rapportons ici les résultats quantitatifs relatifs à la fidélité prédictive et à la cohérence symbolique. Les dimensions de contrôle en aval, de généralisation et de robustesse ne sont pas détaillées dans les résultats principaux.

5.1 Implémentation

Architecture de base du WM. Notre cadre *NS-MAWM*¹ s'appuie sur une architecture de MAWM partagé et est implémenté en PyTorch. Nous utilisons un JOPM centralisé comprenant (i) un encodeur partagé Enc^j sur les observations conjointes, (ii) un noyau de dynamique latente fondé sur un LSTM [27], et (iii) un décodeur Dec^j prédisant l'observation conjointe suivante. Les observations conjointes sont concaténées le long de la dimension agent et traitées par des MLP avec activations ReLU. Les caractéristiques discrètes structurées sont représentées en encodage *one-hot* et traitées comme sorties continues pendant l'entraînement ; lors de l'inférence, une discrétisation par *argmax* est appliquée aux blocs catégoriels correspondants. Les caractéristiques continues sont, elles, prédites directement. La perte de prédiction est $\mathcal{L}_{\text{pred}} = \sum_{k \in \mathcal{F}_{\text{cont}}} \|\hat{f}_k - f_k\|^2$, où $\hat{f}_k$ et f_k désignent respectivement la valeur prédite et la valeur cible de la caractéristique continue k . Tous les composants neuronaux sont optimisés avec l'optimiseur Adam [28], avec un taux d'apprentissage fixe.

1. Une implémentation de NS-MAWM et le détail complet des expériences (y compris les hyperparamètres, architectures et définitions de règles) sont disponibles à l'adresse <https://github.com/julien6/NS-MAWM>.

Composants neuro-symboliques. L'opérateur de transition symbolique $\mathcal{T}_s^j$ est implémenté comme un moteur de règles Python léger. Chaque règle produit de manière déterministe un sous-ensemble de caractéristiques déterminables $\omega_{t+1}^{d,j}$ et un masque correspondant $\mathcal{M}_d$. Cette conception modulaire prend en charge l'activation sélective des règles pour des études d'ablation et de robustesse. Nous évaluons les trois stratégies d'intégration présentées plus haut : régularisation de cohérence symbolique via une perte auxiliaire inspirée de la perte sémantique [14, 15], projection symbolique à l'inférence et dynamique symbolique résiduelle, qui restreint la prédiction neuronale aux caractéristiques non déterminables. Nous considérons en outre un opérateur de correction symbolique en inférence $\mathcal{C}^s$, qui impose des contraintes de validité (telles que l'exclusivité mutuelle ou la faisabilité spatiale) à l'aide d'opérateurs simples de projection et de discrétisation [16].

Données d'entraînement et interfaces. Les WMs sont entraînés hors ligne à partir de mémoires de rejeu collectées avec des politiques aléatoires ou faiblement exploratoires. Nous nous appuyons sur des interfaces MARL standard : *Overcooked-AI* [18] et le jeu de référence *SMACv2* [20]. Ces mémoires de rejeu stockent les observations conjointes, les actions et les observations suivantes. Pour évaluer la frugalité en données, les modèles sont entraînés sur plusieurs tailles de jeux de données (avec trois tailles notées N_{small} , N_{med} et N_{full}). Dans nos expériences, ces tailles correspondent respectivement à 10^4 , 5×10^4 et 2×10^5 transitions, tout en conservant des architectures et des périodes d'entraînement fixes entre méthodes.

Sélection d'hyperparamètres. Les hyperparamètres neuronaux (taux d'apprentissage, dimension latente, nombre d'unités du LSTM, profondeur et largeur des MLP) sont sélectionnés automatiquement en minimisant la perte de prédiction de validation via la librairie Optuna [29]. L'optimisation d'hyperparamètres est appliquée exclusivement aux composants neuronaux et indépendamment des règles symboliques, avec des espaces de recherche et budgets identiques entre méthodes. Les hyperparamètres sélectionnés sont fixes pour toutes les expériences ultérieures.

5.2 Environnements et ensembles de règles

Nous considérons quatre environnements de test, choisis pour couvrir des dynamiques discrètes et

continues ainsi que des formes variées d’interactions multi-agents :

(E1) *Gridcraft*². Un environnement en grille de type *Minecraft* (discret, partiellement observable) avec n agents, murs/obstacles et objets typés. Les observations sont des caractéristiques structurées (positions relatives, occupation, présence d’objets), rendant explicites les invariants et équivariances. Les règles¹ incluent l’évitement des collisions, les contraintes de frontière, la persistance des objets, et les équivariances de mouvement.

(E2) *Overcooked* [18] (discret, coordination coopérative). Nous utilisons des configurations *Overcooked* caractérisées par des récompenses clairsemées et de fortes exigences de coordination. Les règles¹ capturent les contraintes de transition d’état (interactions pickup/drop), les états d’objets mutuellement exclusifs, et les contraintes de mouvement spatial.

(E3) *Predator Prey* [19] (continu ou mixte, interaction multi-agent). Nous utilisons un environnement *Predator Prey* standard avec positions et vitesses continues (ou actions discrètes mixtes). Les règles¹ encodent des contraintes cinématiques (vitesse bornée), des conditions de capture basées sur la proximité, et la persistance.

(E4) *SMACv2* [20] (*StarCraft Multi-Agent Challenge* v2, partiellement observable). Nous évaluons un sous-ensemble de scénarios *SMACv2* avec des tailles d’équipe variables. Les règles¹ se concentrent sur la faisabilité du mouvement et les invariances conditionnées par l’action (par exemple, si un agent ne bouge pas, sa position reste cohérente ; contraintes liées au temps de rechargement des actions).

5.3 Ressources de calcul

Les expériences ont été menées sur le cluster *Iris* (Université du Luxembourg). Les nœuds GPU sont équipés de 4 NVIDIA Tesla V100 SXM2 (entre 16 et 32 GB) associés à des processeurs Intel Xeon Skylake, et les nœuds *bigmem*.

5.4 Cadre d’évaluation

Bases de comparaison. Nous comparons un modèle du monde multi-agents purement neuronal (**MAWM (neuronal)**) à trois variantes NS-MAWM correspondant aux stratégies de régularisation de cohérence symbolique, de projection

symbolique et de dynamique symbolique résiduelle. Toutes les méthodes partagent la même architecture neuronale de base et le même budget d’entraînement. La post-correction symbolique $\mathcal{C}^s$ est désactivée par défaut.

Fidélité prédictive. La précision des prédictions est évaluée à un pas et sur des simulations d’horizon $H = 25$, où les prédictions du modèle sont réinjectées comme entrées. Nous rapportons l’erreur multi-pas agrégée $\text{MSE}_H = \frac{1}{H} \sum_{t=1}^H \mathbb{E}[\|\hat{\omega}_t^j - \omega_t^j\|_2^2]$, moyennée sur les trajectoires.

Cohérence symbolique. La cohérence symbolique est mesurée par le RVR défini en Équation 5, calculé sur des simulations en boucle ouverte, qui quantifie les violations des caractéristiques déterminables $\mathcal{F}^d$. Pour les stratégies de projection et résiduelle, les caractéristiques déterminables sont imposées par construction, donnant un RVR égal à 0 ; le RVR diagnostique donc principalement le modèle neuronal de base et la régularisation symbolique.

Généralisation et robustesse. La généralisation est étudiée sur des configurations hors distribution (plans inédits, nombres d’agents variables, scénarios *SMACv2* alternatifs). La robustesse à une connaissance symbolique incomplète est examinée en supprimant aléatoirement une fraction $\rho \in \{0.25, 0.5\}$ des règles symboliques. Ces deux dimensions relèvent du protocole expérimental global, mais ne sont pas détaillées dans les résultats quantitatifs principaux rapportés ici.

Protocole. Pour chaque environnement, toutes les méthodes sont entraînées sur le même jeu de données hors ligne selon des protocoles comparables, puis évaluées sur des trajectoires distinctes. Les résultats sont rapportés sous la forme moyenne $\pm$ erreur standard sur 5 exécutions avec graines aléatoires distinctes. L’analyse qui suit reste descriptive et porte sur les écarts moyens observés entre variantes à budget expérimental identique.

6 Résultats

Le Tableau 1 présente les résultats, notamment la fidélité prédictive et la cohérence symbolique.

Précision des prédictions à long horizon et structuration multi-agent (G1). Dans tous les environnements évalués, NS-MAWM obtient de meilleures moyennes de fidélité prédictive à long

². Une version est disponible à l’adresse : <https://github.com/julien6/Gridcraft>.

Méthode	Gridcraft		Overcooked		Predator Prey		SMACv2	
	MSE _H ↓	RVR ↓	MSE _H ↓	RVR ↓	MSE _H ↓	RVR ↓	MSE _H ↓	RVR ↓
MAWM (neuronal)	0.092 ± 0.005	0.184 ± 0.014	0.137 ± 0.009	0.231 ± 0.016	0.081 ± 0.005	0.156 ± 0.011	0.164 ± 0.011	0.198 ± 0.014
NS-MAWM (Régularisation)	0.071 ± 0.004	0.061 ± 0.008	0.101 ± 0.007	0.084 ± 0.010	0.067 ± 0.004	0.052 ± 0.007	0.131 ± 0.008	0.073 ± 0.009
NS-MAWM (Projection)	0.068 ± 0.003	0.000 ± 0.000	0.094 ± 0.006	0.000 ± 0.000	0.065 ± 0.004	0.000 ± 0.000	0.126 ± 0.008	0.000 ± 0.000
NS-MAWM (Résiduel)	0.063 ± 0.003	0.000 ± 0.000	0.089 ± 0.006	0.000 ± 0.000	0.061 ± 0.003	0.000 ± 0.000	0.119 ± 0.007	0.000 ± 0.000

TABLE 1 – Évaluation quantitative. Les résultats sont rapportés en moyenne ± erreur standard sur 5 graines aléatoires distinctes. MSE_H est l’erreur quadratique moyenne sur des simulations ouvertes d’horizon H (plus petit est meilleur). RVR est le taux de violation des règles. Pour les variantes projection et résiduelle, le RVR vaut 0 par construction sur $\mathcal{F}^d$.

horizon que MAWM. Sur *Gridcraft*, la stratégie résiduelle fait passer la MSE_H de 0.092 à 0.063 (environ 31.5% de réduction relative), avec des gains du même ordre sur *Overcooked* et *SMACv2*.

Cohérence symbolique et respect des contraintes (G2, G3). Le RVR met en évidence l’écart entre précision numérique et validité sémantique : malgré des MSE_H modérées, MAWM viole en moyenne entre 15.6% et 23.1% des caractéristiques déterminables selon l’environnement. La régularisation réduit ce taux d’environ un facteur trois, par exemple de 0.231 à 0.084 dans *Overcooked*, tandis que projection et résiduel obtiennent un RVR nul par construction. Pour ces deux dernières variantes, le RVR joue donc surtout un rôle de vérification de cohérence avec le mécanisme imposé, et non de discrimination fine entre méthodes.

Comparaison des stratégies d’intégration. Toutes les variantes NS-MAWM obtiennent de meilleures moyennes que la base neuronale. La régularisation est la plus simple à intégrer, mais laisse des violations résiduelles ; la projection garantit la conformité des caractéristiques déterminables à l’inférence. La dynamique symbolique résiduelle fournit ici le meilleur compromis entre fidélité prédictive et cohérence explicite.

Analyse agrégée inter-environnements. En moyenne sur les quatre environnements, la MSE_H passe de 0.118 (MAWM) à 0.093 (régularisation), 0.088 (projection) et 0.083 (résiduel), soit des réductions relatives d’environ 21.2%, 25.4% et 29.7%. Pour la cohérence symbolique, le RVR moyen chute de 0.192 (MAWM) à 0.068 (régularisation), tandis que projection et résiduel atteignent 0 sur $\mathcal{F}^d$ par construction.

Lecture par environnement. Les gains les plus nets en MSE_H apparaissent dans *Overcooked* et *SMACv2*, où les interactions et les dépendances temporelles sont les plus fortes. *Gridcraft* confirme l’apport du biais symbolique sur des règles spatiales explicites, tandis que *Predator Prey* montre que l’approche reste utile en dynamique continue ou mixte.

Hiérarchie des méthodes selon les environnements. La hiérarchie observée sur les moyennes est stable : *résiduel* < *projection* < *régularisation* < *neuronal* en MSE_H sur les quatre environnements. L’écart entre résiduel et projection reste modéré mais récurrent (par exemple 0.089 contre 0.094 sur *Overcooked*, 0.119 contre 0.126 sur *SMACv2*), ce qui indique qu’apprendre explicitement la composante non déterminable peut apporter un gain additionnel au-delà de la seule correction symbolique.

Lecture vis-à-vis des gaps (G1, G2, G3). Vis-à-vis de **G1**, les baisses de MSE_H indiquent que la structuration multi-agent et les contraintes symboliques n’introduisent pas de dégradation visible de précision ; elles semblent au contraire limiter l’accumulation d’erreurs. Pour **G2** et **G3**, la comparaison entre MAWM et NS-MAWM montre que la version neuronale conserve des violations marquées alors que les variantes projetée et résiduelle imposent la cohérence sur $\mathcal{F}^d$. La régularisation occupe une position intermédiaire utile : elle réduit fortement le RVR sans imposer de correction dure à l’inférence. Pour une intégration minimale dans une chaîne de traitement existante, la régularisation est souvent l’option la plus simple. Quand la validité symbolique doit être garantie à l’inférence, la projection est la plus adaptée. Si le critère retenu est le meilleur compromis global précision/cohérence, la variante résiduelle est la plus robuste.

7 Conclusion et travaux futurs

NS-MAWM traite le cas où des modèles du monde multi-agents précis numériquement restent incohérents vis-à-vis des règles de l’environnement. La contribution tient à l’intégration explicite de règles symboliques dans la prédiction multi-agent via trois stratégies complémentaires, réunies dans un cadre unique et comparées sous un protocole qui mesure à la fois la précision et la cohérence logique. Les résultats rapportés montrent une réduction de la dérive sémantique à long horizon ainsi que des gains de fidélité prédictive et de cohérence symbolique.

Cependant, NS-MAWM entraîne un surcoût com-

putationnel, pose des défis de scalabilité à mesure que le nombre d’agents, de caractéristiques ou de règles symboliques augmente, et repose sur des règles symboliques conçues à la main. Les travaux futurs exploreront : (1) l’utilisation de grands modèles de langage pour assister l’extraction ou le raffinement automatique des règles ; (2) le développement de formulations matricielles des transitions symboliques pour réduire le surcoût et améliorer la scalabilité ; et (3) l’adoption de cadres numériques hautes performances tels que JAX pour permettre une vectorisation efficace, la compilation, et l’accélération matérielle.

Références

- [1] D. HA et al. « World Models ». In : *arXiv preprint arXiv :1803.10122* (2018). arXiv :1803.10122.
- [2] D. HAFNER et al. « Learning Latent Dynamics for Planning from Pixels ». In : *Proc. of the 36th Int. Conf. on Machine Learning*. T. 97. Proc. of Machine Learning Research. PMLR, sept. 2019, p. 2555-2565.
- [3] D. HAFNER et al. « Dream to Control : Learning Behaviors by Latent Imagination ». In : *Int. Conf. on Learning Representations*. 2020.
- [4] D. HAFNER et al. « Mastering Atari with Discrete World Models ». In : *Int. Conf. on Learning Representations*. 2021.
- [5] A. WONG et al. « Deep multiagent reinforcement learning : challenges and directions ». In : *Artificial Intelligence Review* 56.6 (juin 2023), p. 5023-5056.
- [6] A. VENUGOPAL et al. « MABL : Bi-Level Latent-Variable World Model for Sample-Efficient Multi-Agent Reinforcement Learning ». In : *Proc. of the 23rd Int. Conf. on Autonomous Agents and Multiagent Systems*. Auckland, New Zealand : Int. Foundation for Autonomous Agents et Multiagent Systems, 2024, p. 1865-1873.
- [7] D. J. AGRAVANTE et al. « Learning Neuro-Symbolic World Models with Conversational Proprioception ». In : *Proc. of the 61st Annual Meeting of the Association for Computational Linguistics*. Toronto, Canada : Association for Computational Linguistics, juill. 2023, p. 648-656.
- [8] T. KIPF et al. « Contrastive Learning of Structured World Models ». In : *Int. Conf. on Learning Representations*. 2020.
- [9] E. TALVITIE. « Model Regularization for Stable Sample Rollouts ». In : *Proc. of the 30th Conf. on Uncertainty in Artificial Intelligence*. AUAI Press, 2014, p. 780-789.
- [10] J. SOULE et al. « An Organizationally-Oriented Approach to Enhancing Explainability and Control in Multi-Agent Reinforcement Learning ». In : *Proc. of the 24th Int. Conf. on Autonomous Agents and Multiagent Systems*. 2025.
- [11] J. C. BALLOCH et al. « Neuro-Symbolic World Models for Adapting to Open World Novelty ». In : *Proc. of the Int. Conf. on Autonomous Agents and Multiagent Systems*. London, United Kingdom : Int. Foundation for Autonomous Agents et Multiagent Systems, 2023, p. 2848-2850.
- [12] L. ZHANG et al. « World Model as a Graph : Learning Latent Landmarks for Planning ». In : *Proc. of the 38th Int. Conf. on Machine Learning*. T. 139. Proc. of Machine Learning Research. PMLR, 18–24 Jul 2021, p. 12611-12620.
- [13] D. WILLEMSSEN et al. « MAMBPO : Sample-Efficient Multi-Robot Reinforcement Learning Using Learned World Models ». In : *2021 IEEE/RSJ Int. Conf. on Intelligent Robots and Systems*. 2021, p. 5635-5640.
- [14] J. XU et al. « A Semantic Loss Function for Deep Learning with Symbolic Knowledge ». In : *Proc. of the 35th Int. Conf. on Machine Learning*. T. 80. Proc. of Machine Learning Research. PMLR, oct. 2018, p. 5502-5511.
- [15] F. YANG et al. « Differentiable Learning of Logical Rules for Knowledge Base Reasoning ». In : *Advances in Neural Information Processing Systems*. T. 30. Curran Associates, Inc., 2017.
- [16] A. d. GARCEZ et al. « Neurosymbolic AI : The 3rd Wave ». In : *Artificial Intelligence Review* 56.11 (nov. 2023), p. 12387-12406.
- [17] R. MANHAEVE et al. « DeepProbLog : Neural Probabilistic Logic Programming ». In : *Advances in Neural Information Processing Systems*. T. 31. Curran Associates, Inc., 2018.
- [18] M. CARROLL et al. « Overcooked-AI : A Benchmark for Multi-Agent Learning under Partial Observability ». In : *2020 IEEE/RSJ Int. Conf. on Intelligent Robots and Systems*. 2020, p. 2374-2380.
- [19] R. LOWE et al. « Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments ». In : *Advances in Neural Information Processing Systems*. T. 30. 2017, p. 6379-6390.
- [20] B. ELLIS et al. « SMACv2 : An Improved Benchmark for Cooperative Multi-Agent Reinforcement Learning ». In : *Advances in Neural Information Processing Systems*. T. 36. Curran Associates, Inc., 2023, p. 37567-37593.
- [21] Z. XU et al. « Mingling Foresight with Imagination : Model-Based Cooperative Multi-Agent Reinforcement Learning ». In : *Advances in Neural Information Processing Systems*. T. 35. Curran Associates, Inc., 2022, p. 11327-11340.
- [22] H. NEKOEI et al. « Dealing With Non-Stationarity in Decentralized Cooperative Multi-Agent Deep Reinforcement Learning via Multi-Timescale Learning ». In : *Proc. of The 2nd Conf. on Lifelong Learning Agents*. T. 232. Proc. of Machine Learning Research. PMLR, 22–25 Aug 2023, p. 376-398.
- [23] X. YU et al. « Model-Based Opponent Modeling ». In : *Advances in Neural Information Processing Systems*. T. 35. Curran Associates, Inc., 2022, p. 28208-28221.
- [24] F. A. OLIEHOEK et al. *A Concise Introduction to Decentralized POMDPs*. Springer, 2016.
- [25] T. M. MOERLAND et al. « Model-based Reinforcement Learning : A Survey ». In : *Foundations and Trends in Machine Learning* 16.1 (jan. 2023), p. 1-118.
- [26] X. WANG et al. *Model-based Multi-agent Reinforcement Learning : Recent Progress and Prospects*. 2022.
- [27] S. HOCHREITER et al. « Long Short-Term Memory ». In : *Neural Computation* 9.8 (1997), p. 1735-1780.
- [28] D. P. KINGMA et al. « Adam : A Method for Stochastic Optimization ». In : *Int. Conf. on Learning Representations*. 2015.
- [29] T. AKIBA et al. « Optuna : A Next-generation Hyperparameter Optimization Framework ». In : *Proc. of the 25th ACM SIGKDD Int. Conf. on Knowledge Discovery & Data Mining*. Anchorage, AK, USA : Association for Computing Machinery, 2019, p. 2623-2631.